

Statystyczne metody przetwarzania danych

Cechy i przestrzenie cech

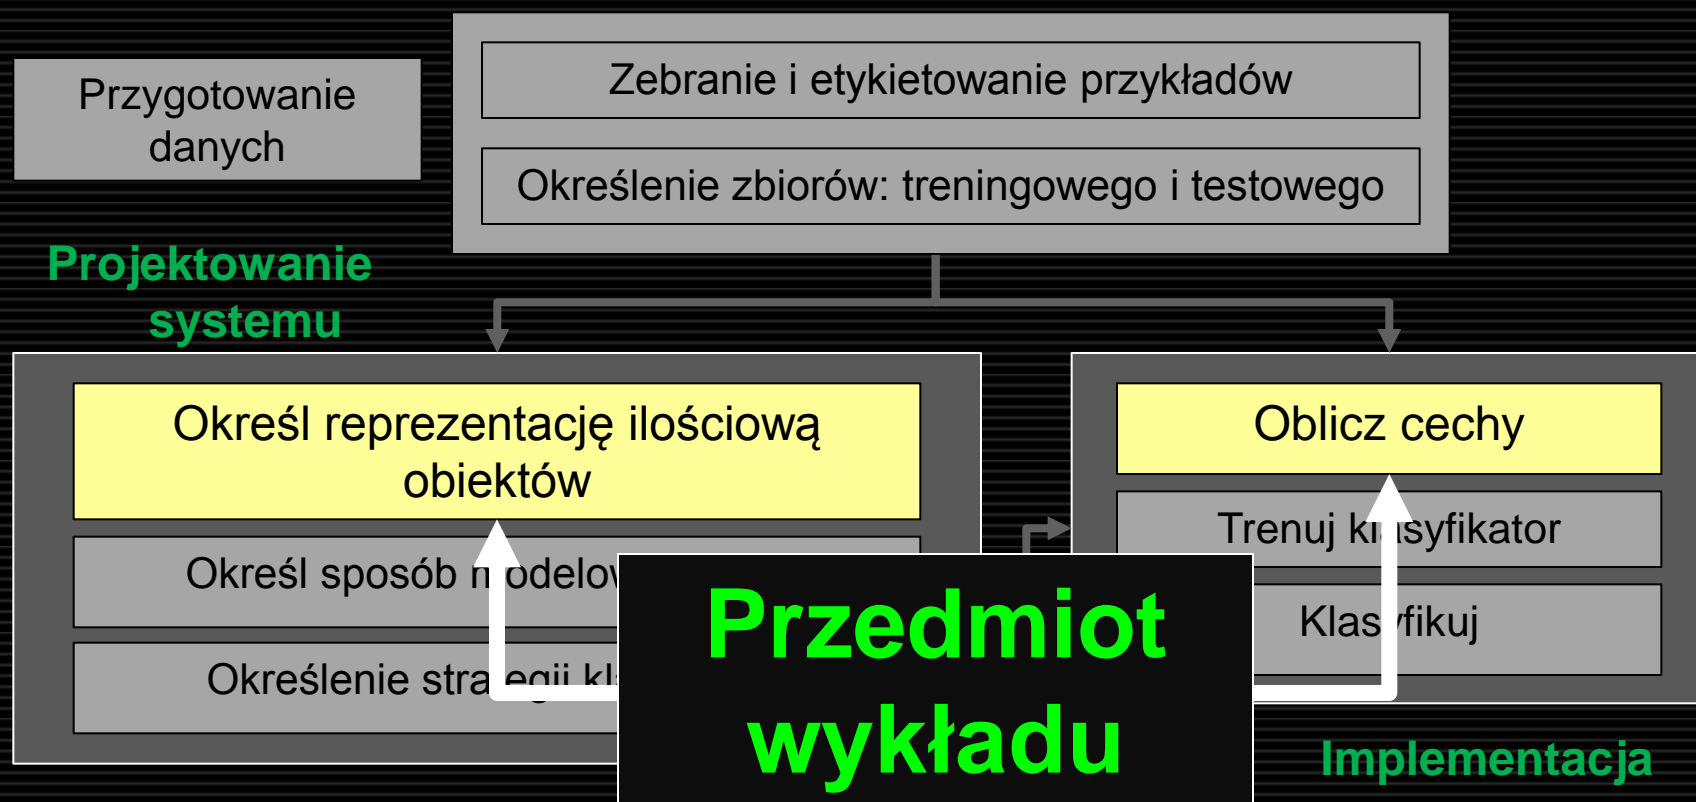
Krzysztof Ślot

*Instytut Informatyki Stosowanej
Politechnika Łódzka*

Wprowadzenie

- **Etapy procedury rozpoznawania**

- Przetwarzanie wstępne, obejmuje ekstrakcję obiektu z tła
- Projektowanie systemu rozpoznawania
- Klasyfikacja, wykorzystująca wybrane cechy i zbudowane modele klas



Wprowadzenie

- Unifikacja różnych typów zadań**

- Analiza przynależności do klasy przeprowadzana w przestrzeniach cech

Akwizycja i przetwarzanie
wstępne



**Cechy: ilościowa
reprezentacja obiektów**



$$\mathbf{F}_1^\alpha = [f_0^\alpha, f_1^\alpha \dots f_{n-1}^\alpha]$$

$$\mathbf{F}_2^\alpha = [f_0^\alpha, f_1^\alpha \dots f_{n-1}^\alpha]$$


$$\mathbf{F}^\alpha = [f_0^\alpha, f_1^\alpha \dots f_{n-1}^\alpha]$$




Reprezentacja w
przestrzeni cech




$$\mathbf{F}^\beta = [f_0^\beta, f_1^\beta \dots f_{m-1}^\beta]$$



Mowa



$$\mathbf{F}^\gamma = [f_0^\gamma, f_1^\gamma \dots f_{o-1}^\gamma]$$




Cechy i przestrzenie cech

Definicje

- Cecha: charakterystyka ilościowa
- Przestrzeń cech: przestrzeń metryczna wyznaczona przez cechy

Przestrzeń cech dla rozpoznawania

- Powinny być ‘najlepsze’ (**‘dyskryminatywne’**)
- Typowo brak wskazówek wyboru cech (które, ile)



Wektor cech

$[d_{LP}, A_L, B_L, C_L, D_L, A_R, B_R, C_R, D_R, w, h, d_1, d_2, d_{OBL}, d_{OBP} \dots]$

Staje się coraz dłuższy ...

np. kilkaset tysięcy elementów (Eigenfaces)


Wymiar wektora – wymiar przestrzeni cech

- Wielowymiarowe przestrzenie cech

Opis obiektów = przestrzeń wielkowymiarowa?

Hipoteza

- Użyć wszystkich możliwych do wyznaczenia cech (ponieważ nie wiadomo, które są ważne)



$$\begin{bmatrix} d \\ A_L \\ B_l \\ \vdots \end{bmatrix}$$

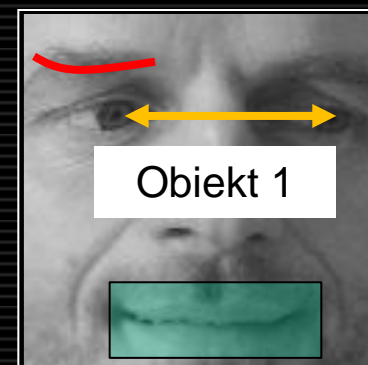
$$d : 12.35 \approx 12.2 \approx 12.4 \approx \dots$$

$$A_L : 2.3 \neq -1.9 \neq 4.3 \dots$$

:

$$w : 6 \neq 8.6 \neq 8.1 \dots$$

:




- Brak zgodności obiektów z wzorcem dla różnych cech

Podobieństwo

$$D = \sqrt{(d_w - d_x)^2 + (A_{Lw} - A_{Lx})^2 + \dots}$$

- „Zła” cecha to ‘szum’ obliczania podobieństwa: losowe wartości miary podobieństwa (D)




99% fiasko

Opis obiektów = przestrzeń wielkowymiarowa?

~~Hipoteza~~

- ~~Użyć wszystkich dobrych cech (np. 100)~~



$$\begin{bmatrix} d/d_N \\ d/d_{K_LP} \\ \vdots \end{bmatrix}$$



$$d/d_N : 1.35 \approx 1.29 \approx 1.34 \approx \dots$$

$$d/d_{K_LP} : 3.2 \approx 3.4 \approx 3.7 \approx \dots$$

:



- Wyniki obliczania podobieństwa jest wiarygodny, ale ...



3D : : 0.1pr./komórkę
4D : : 0.01pr./komórkę

Złe modele

Kłątwa wymiarowości

Redukcja wymiarowości problemu rozpoznawania

- **Wymiar przestrzeni cech powinien być jak najmniejszy**
 - Dostępny zbiór cech będzie typowo nadmiarowy, będzie zawierał cechy dobre, złe i średnie
 - Konieczne będzie dokonanie redukcji tego zbioru w oparciu o odpowiednio sformułowane kryteria
- **Redukcja wymiarowości**
 - Poszukiwanie niskowymiarowej reprezentacji obiektów

$$\mathbb{R}^D \rightarrow \mathbb{R}^d, \quad d \ll D$$

$$\mathbf{F} = [f_0, f_1 \dots f_{D-1}] \rightarrow \boldsymbol{\xi} = [\xi_0, \xi_1 \dots \xi_{d-1}]$$

- **Strategie redukcji wymiarowości**
 - **Selekcja cech**
 - **Ekstrakcja cech**

Selekcja cech

- **Sformułowanie problemu**

- Znajdź podzbiór oryginalnego, nadmiarowego zbioru cech, zapewniający największą skuteczność rozpoznawania (cechy najlepsze)

- **Zagadnienia cząstkowe**

1. Ocena jakości zbioru cech
2. Sposób generacji podzbiorów do sprawdzenia

1. **Kryteria oceny jakości podzbioru**

- Ocena skuteczności klasyfikacji
- Prognozowanie skuteczności (miary statystyczne)

- **Ocena skuteczności klasyfikacji**

- Narzucające się kryterium
- Ocena pośrednia: wkleja ocenę jakości cech i jakości przyjętej metody klasyfikacji, jest złożona obliczeniowo (dla każdego zbioru konieczne tworzenie osobnego systemu klasyfikacji i ocena wyników jego działania)

Statystyczne kryteria selekcji cech

- **Właściwości**

- Zalety: prostota koncepcyjna i efektywność obliczeniowa
- Wady: używanie założeń ograniczających ogólność rozważań

- **Wskazówki wyboru przestrzeni cech**

- Dobra przestrzeń zapewnia dobrą separację klas (próbek klas)
- Dobra separacja: 'chmury' próbek danej klasy znajdują się w odrębnych (możliwych do (łatwego) rozdzielenia) regionach przestrzeni cech

- **Podstawowe statystyki rozkładów 1D**

- Średnia (arytmetyczna, geometryczna)
- Wariancja
- Inne momenty zwykłe
- Inne momenty centralne
- ...

$$E(X) = \sum_{i=0}^{n-1} p(x_i)x_i$$

$$\mu = \frac{1}{n} \sum_{i=0}^{n-1} x_i$$

$$\mu_G = \frac{1}{n} \prod_{i=0}^{n-1} x_i$$

$$\sigma^2 = E(X - \mu)^2 = E(X)^2 - \mu^2$$

$$s = E(X - \mu)^3$$

**Przykład:
oblicz
podstawowe
statystyki
zbioru**

$$A = \{1, 2, 3, 4, 5\}$$

Selekcja cech w przestrzeni 1D

• Założenia

- Obiekty są opisane za pomocą jednej cechy, rozważamy 2 klasy
- Celem jest ocena 'separowalności' (możliwości separacji) klas


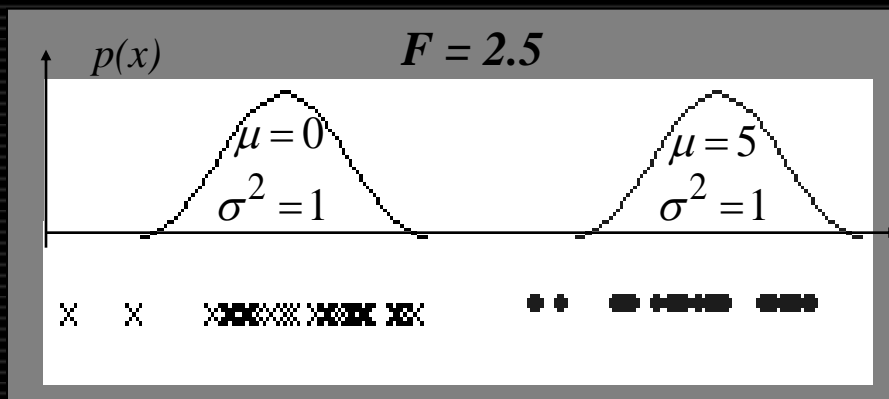
• Kryterium statystyczne

- Dobra separacja: wartości średnie klas leżą daleko od siebie, wariancje w obrębie klas są jak najmniejsze

Współczynnik dyskryminacji liniowej Fishera: 1D, 2 klasy

S_b – rozrzut między-klasowy, S_w rozrzut wewnątrz-klasowy

$$F = \frac{S_b}{S_w} = \frac{|m_A - m_B|}{\sigma_A + \sigma_B}$$



Przykład

$$\mathbf{x}^A = \{ (-1, 0), (1, 1), \{0, 0\} \}, \mathbf{x}^B = \{ (2, -1), (0, 0), \{-2, -2\} \}$$

Selekcja cech w przestrzeniach n-wymiarowych

- Statystyczna reprezentacja danych w n-wymiarach

- Wartość średnia: wektor
- Zmienność: macierz kowariancji

Przykłady klasy A

$$A = \left\{ \begin{bmatrix} x_0^0 \\ \vdots \\ x_{n-1}^0 \end{bmatrix}, \begin{bmatrix} x_0^1 \\ \vdots \\ x_{n-1}^1 \end{bmatrix}, \dots, \begin{bmatrix} x_0^m \\ \vdots \\ x_{n-1}^m \end{bmatrix} \right\}$$

Średnia

$$\boldsymbol{\mu} = E(\mathbf{X}) = \begin{bmatrix} E(x_0) \\ \vdots \\ E(x_{n-1}) \end{bmatrix}$$

Kowariancja

$$\text{Cov}(X) = E[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^T] = \sum_{i=0}^{n-1} p(\mathbf{x}_i)(\mathbf{x}_i - \boldsymbol{\mu})(\mathbf{x}_i - \boldsymbol{\mu})^T$$

Macierz kowariancji

$$\text{Cov}(X) = \begin{bmatrix} \sigma_{00}^2 = c_{00} & c_{01} & \dots \\ c_{10} & \sigma_{11}^2 = c_{11} & \dots \\ \dots & \dots & \dots \end{bmatrix}$$

Współczynnik Fishera dla n-D

• Założenia: 2 klasy, 2D

- Jak określić odległość między klasami (dla 1D: moduł różnicy średnich)?
- Jak opisać zmienność w obrębie klasy (1D: suma odchyleń)?

• Rozrzut międzyklasowy dla 2 klas w przestrzeni 2D

- Odległość między wartościami średnimi (długość wektora)

$$S_b = \| \boldsymbol{\mu}^A - \boldsymbol{\mu}^B \|$$

• Rozrzut wewnątrzklasowy dla 2 klas, 2D

$$S_w = \det(C^c) = \det \begin{pmatrix} \sigma_0^2 & \dots & c_{0n} \\ \vdots & & \vdots \\ c_{n0} & \dots & \sigma_n^2 \end{pmatrix}$$

Wyznacznik macierzy kowariancji

$$\det \begin{pmatrix} a_0 & b_0 \\ a_1 & b_1 \end{pmatrix} = a_0 b_1 - b_0 a_1 = \mathbf{a} \times \mathbf{b} = ab \sin(\mathbf{a}, \mathbf{b})$$

Objętość równoległościanu wyznaczonego przez wektory (kolumny) macierzy kowariancji

$$\mathbf{x}^A = \{ (-1, 0, -1), (1, 1, 1), \{0, 0, 0\} \}$$

Współczynnik Fishera dla n-D

- Przypadek 2D, 2 klasy

- Kryterium separowalności (Fishera) – analogiczna zasada: relacja między rozrzutami: międzyklasowym i wewnątrzklasowym

Macierz kowariancji

$$C^c = E[(\mathbf{x}^c - \boldsymbol{\mu}^c)(\mathbf{x}^c - \boldsymbol{\mu}^c)^T]$$



Macierz rozrzutu

$$S^c = \sum_{i=1}^N (\mathbf{X}_i^c - \boldsymbol{\mu}^c)(\mathbf{X}_i^c - \boldsymbol{\mu}^c)^T$$

- Alternatywne formy współczynnika Fishera

Dokładna
estymacja
rozrzutu

$$F = \frac{S_m}{S_w} = \frac{\|\boldsymbol{\mu}^A - \boldsymbol{\mu}^B\|}{\det(S^A) + \det(S^B)}$$

Zgrubna
estymacja

$$F = \frac{S_m}{S_w} = \frac{\|\boldsymbol{\mu}^A - \boldsymbol{\mu}^B\|}{\text{Tr}(S^A) + \text{Tr}(S^B)}$$

- Wyrażenia są ogólne i dotyczą zmiennych n-wymiarowych

Współczynnik Fishera dla n-D

- **Przypadek najogólniejszy: wiele klas, n-wymiarów**

- Idea kryterium bez zmian: relacja rozrzutu międzyklasowego do wewnątrz-klasowego

- **Rozrzut wewnątrzklasowy**

- Miara identyczna jak poprzednio – suma wyznaczników lub śladów indywidualnych macierzy rozrzutu


$$S_w = \sum_{i=1}^C \det(\mathbf{S}^i) \quad \text{lub} \quad S_w = \sum_{i=1}^C \text{Tr}(\mathbf{S}^i)$$

- **Rozrzut międzyklasowy**

- Konieczna redefinicja (mamy do czynienia z wieloma wartościami średnimi)

Współczynnik Fishera

- Rozrzut międzyklasowy dla wielu klas i przestrzeni n-D**
 - Idea: potraktowanie wartości średnich klas jako próbek nowego, hipotetycznego rozkładu i określenie rozrzutu wewnątrzklasowego tego rozkładu



Rozrzut międzyklasowy

$$\tilde{S}_B = \sum_{i=1}^C (\mu^i - \mu)(\mu^i - \mu)^T$$

 μ^i

Średnia klasy 'i'

 μ

Średnia rozkładu


Współczynnik Fishera C-klas, n-wymiarów

$$F = \frac{S_m}{S_w} = \frac{\det(\tilde{S}_B)}{\sum_{i=1}^C \det(S^i)} \quad , \quad F = \frac{S_m}{S_w} = \frac{\text{Tr}(\tilde{S}_B)}{\sum_{i=1}^C \text{Tr}(S^i)}$$

Selekcja cech z użyciem wsp. Fishera

- **Właściwości**

- Prosta i szybka procedura
- Zakłada, że rozkłady próbek klas mają charakter Gaussowski



Klasy separowalne nieliniowo

Wartość współczynnika Fishera
sugeruje brak możliwości separacji klas

Selekcja cech

- **Zasadnicze zagadnienia problematyki selekcji cech**

- Wybór optymalnej przestrzeni cech (omówiony)
- Określenie systematycznej metody tworzenia podzbiorów cech

- **Generacja podzbiorów zbioru cech**

- Selekcja wymaga sprawdzenia każdego podzbioru
- Generacja wszystkich podzbiorów: zadanie o wykładniczej złożoności obliczeniowej

- **Przykład**

- Liczność zbioru cech: 100
- Cel: wybór optymalnej przestrzeni cech, co najwyżej 10-cio wymiarowej
- Liczba wszystkich podzbiorów:


$$\binom{100}{1} + \binom{100}{2} + \dots + \binom{100}{10}$$

$$\binom{100}{10} = \frac{100 \cdot 99 \cdot 98 \cdot \dots \cdot 91}{1 \cdot 2 \cdot \dots \cdot 10} \approx 17 \cdot 10^{12}$$

Algorytmy generacji podzbiorów

• Metoda B-B

- Budowa drzewa poszukiwań
- „Przycinanie” drzewa – usuwanie węzłów z pewnością prowadzących do gorszych podzbiorów






1. Sprawdzenie dowolnego podzbioru o założonej liczności S_k
2. ‘Wspięcie się’ do wierzchołka z rejestracją kosztu dla kolejnych warstw
3. Ekspansja w dół: jeżeli koszt dla podzbioru większy niż dowolny dotąd zarejestrowany, usuń dalsze poddrzewo,

Metoda B-B generacji podzbiorów

Przykład

1. Jakość podzbioru startowego o docelowej liczności = 50
2. Ekspansja korzenia do poziomu, w którym znaleziono gorszy podzbiór (48), usunięcie poddrzewa (o ile nie przekroczono ustalonej głębokości)
3. Wybór innego podzbioru o docelowej liczebności
4. Iteracyjne powtarzanie procedury




Metoda selekcji przyrostowej

• Założenie

- Monotoniczność funkcji celu (liczniejszy podzbiór ma lepsze właściwości)

• Selekcja przyrostowa (Sequential forward selection - SFS)

- Iteracyjne powiększanie najlepszego podzbioru o licznosci n o kolejny element, dający najlepszy podzbiór $n+1$ - elementowy



• Selekcja redukcyjna (Sequential Backwards selection - SBS)

- Iteracyjna redukcja zbioru o licznosci n o kolejny element, dający najlepszy podzbiór $n-1$ - elementowy

• Złożoność obliczeniowa

$$n + (n-1) + \dots + (n-k+1) < k \cdot n$$

$$<< \frac{n!}{(n-k)!k!}$$